Lec02. 선형회귀 분석

h( )를 어떻게? ⇝ x, θ 선형함수로 ⇝ $h(x)$ 조사 ⇝ θ를 선택 …

목표: $\theta\downarrow$ ⇝ $J(\theta)$ Loss(손실)$\downarrow$ ⇝ 예측$\uparrow$

- GD
  - Batch GD — Σ 예제
  - Stochastic GD — 1 예제
  - Mini Batch GD

정규방정식: $\nabla_\theta J(\theta) = 0$ 이되는 ⇝ θ

(only 선형회귀에서만.)

지도학습	training set → Learning Algorithm → 함수 (h) 주택가격 예측 input: size output: price
함수 h	$h(x) = \theta_0 + \theta_1 x$ 출력값 = 선형함수 입력값 (입력변수 1개)
입력값이 늘어날 때 h	$h(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2$ $= \sum_{j=0}^{2} \theta_j \cdot x_j$ $\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{bmatrix}$ 3차원 파라미터 $x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix}$ 3차원 특징변수 **(선형회귀) θ_0은 필수적이다. (안 그러면 원점만 통과함) 절두법이 최적화가 돼서 구현된 거.

(3)차원 - 수학: 데이터의 가짓수 (좌표축이 몇개인가?) $x \in \mathbb{R}^3$

- 프로그래밍: 데이터가 얼마나 겹겹이 쌓여 있는가 shape = (10, 5, 3)

m, 시퀀스(묶음), n

h 일반화

$$h(x) = \sum_{j=0}^{n} \theta_j \cdot x_j$$

(where $x_0 = 1$)

θ = parameters

m = # training examples
(# rows in table above)
학습데이터

(x, y) = 1 training example

$(x^{(i)}, y^{(i)})$ = i^{th} "

n = # features

x = "input" / features

y = "output" / target variable

$h_\theta(x)$ = $h(\theta)$가 파라미터는 x 입력에서
의존한다는 것을 강조하기 위한 표기

θ 어떻게 파라미터를 선택?	$h(x) \approx y$ for training examples. (가능토록)
$J(\theta)$: 최소제곱법	$J(\theta) = \frac{1}{2} \cdot \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})^2 \rightsquigarrow \underset{\theta}{\text{minimize}}$ (목표는 $J(\theta)$ min)
Gradient Descent 경사하강법	Start with some θ (say $\theta = \vec{0}$) 초기값 keep changing θ to reduce $J(\theta)$ 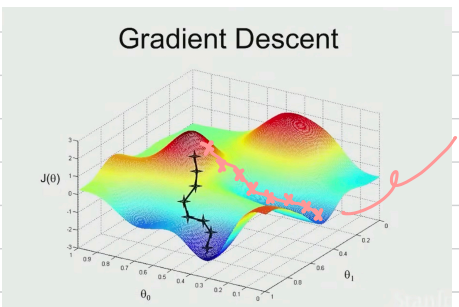 파라미터를 초기화하는 위치에 따라 서로 다른지점에 도달할 수 O. 선형회귀에 경사하강법을 적용하면 지역최저점이 존재하지 X ↳ 전역최저점 말고, 가짜 최저점이 존재하지 않는다는 뜻.

경사하강법 공식화

↳ 최적의 하강도를 초수가 되어 최적의 파라미터를 찾는 방법

(최소제곱법 + 경사하강법)

목표 $J(\theta)$ 도구 반복주

min θ 도출

학습률 (learning rate)

$$\theta_j := \theta_j - \alpha \cdot \boxed{\frac{\partial}{\partial \theta_j} \cdot J(\theta)} \quad (j=0,1,2)$$

대입

θ_j 편미분

도함수가 하강방향을 알려준다.

⊖가 붙은 이유는 '최솟값'을 찾기 위함.

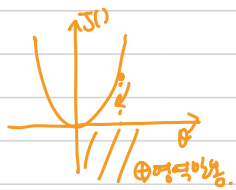

$m=1$
$j=1$

$$J(\theta) = \frac{1}{2} \cdot (h_\theta(x) - y)^2$$

$$\frac{\partial}{\partial \theta_j} \cdot J(\theta) = 2 \cdot \frac{1}{2} \cdot (h_\theta(x) - y) \cdot (h_\theta(x) - y)'$$

n: 특징개수.

$$= (h_\theta(x) - y) \cdot \left(\frac{\partial}{\partial \theta_j} \left(\underbrace{\theta_0 \cdot x_0 + \theta_1 \cdot x_1 + \cdots + \theta_n \cdot x_n}_{\text{j에 해당하는 } \theta\text{만 제외하고 모두 0}} - y \right) \right)$$

$$= (h_\theta(x) - y) \cdot x_j$$

• Gradient Descent Algorithm

$$\theta_j := \theta_j - \alpha \cdot \underbrace{\sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)}}_{\frac{\partial}{\partial \theta_j} \cdot J(\theta)}$$

j가 0, 1, ..., n 까지 반복 & 업데이트
(m수만큼!!)

목표.

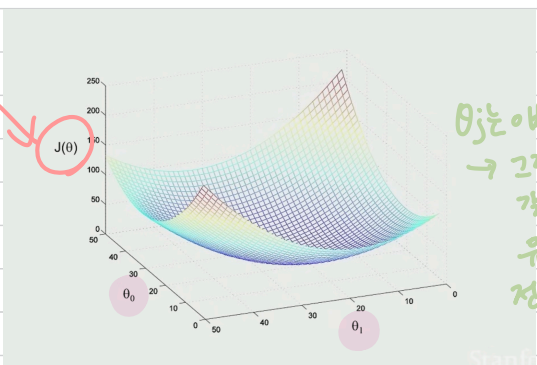

θ_j는 어디든 갈 수 있다.
→ 그래서 국소최저점을 갖지 않거나,
유일한 국소최저점이 전역최저점이 되기도 한다.

목표는 θ의 J(θ)값을 낮추는 것이다.

등고선 살펴보기

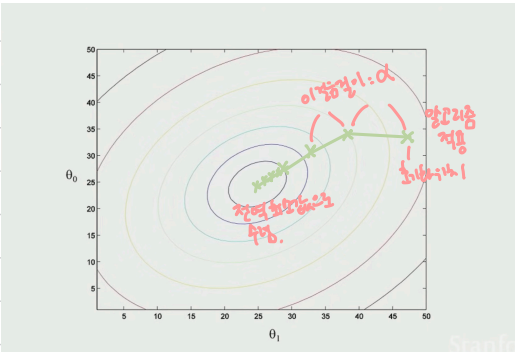

learning rate α

너무 크면 오차↑

너무 작으면 속도↓

실제 Dataset

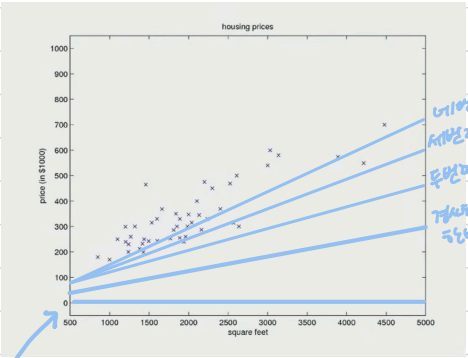

m = 49

파라미터를 $\vec{\theta}$으로 최대한 하는 것은

h()를 최대한 하거나 (θ_0, θ_2 $\vec{\theta}$이 되면 어떤 임의값이라도 0이됨.)

데이터에 맞는 직선을 수평선으로 최대한 하는 것을 의미.

경사하강 알고리즘은

m에 대해 Σ합산하여 미분값을 계산.

m 전부

Batch Gradient desent 라고도 부름.

모든데이터를 하나의 배치로 처리

(But 데이터셋이 큰경우 속도↓

∵ 경사하강법의 한 단계를 수행하기위해서도

파라미터를 한 번 업데이트 하기 위해서도

Σ합계를 계산해야만함.)

배치의 대안
알고리즘.

" stochastic 확률적!!
Gradient
Descent "

Repeat {

for every j

For $i=1$ to m {

$$\theta_j := \theta_j - \alpha \cdot \underbrace{\left(h_\theta(x^{(i)}) - y^{(i)}\right) \cdot x_j^{(i)}}$$

}

}

하나의 예제만으로
경사하강 단계를 수행.

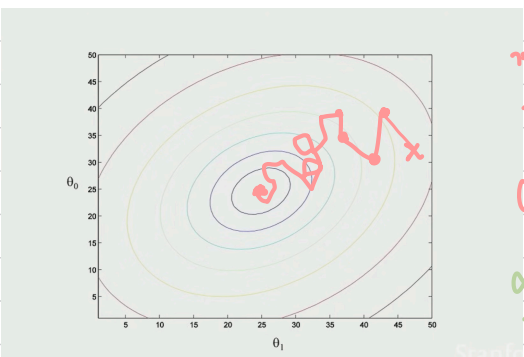

미니배치경사하강법?

신경망은 비선형적이어서
어렵다?

결코 완전히
최적점에 수렴하진X
하지만 목표↑
(데이터셋 큰경우 효율적!)

α를 낮추면
진동이 크기가 줄어듦.

정규방정식	• 선형 회귀 분석에만 적용된다.

$\theta = (\ldots)$ $\quad \theta \in \mathbb{R}^{n+1}$

$$\nabla_\theta \underbrace{J(\theta)}_{\theta\text{에 대한 } J\text{의 미분}} = \begin{bmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \\ \frac{\partial J}{\partial \theta_2} \end{bmatrix}$$

* $(n+1)\times 1$ 행렬 취급.

(3차원 벡터)
θ가 3개 있으니
다 구해야 함!

$$\nabla_\theta J(\theta) \overset{\text{set}\rightarrow}{=} 0$$

미분하고 0으로 설정 (초기값?)
그런 다음 미분값이 0이 되는 θ값을 구함.

* 함수의 최소/최대값은 도함수가 0이 되는 지점임.
→ 그러면 $J(\theta)$에 대한
전역최소점과 비교할 수 있는 서로 공식을 얻게 된다.

강의노트 확인

행렬을 입력받아
행렬의 값을 산출하는 함수의 예시

$A \in \mathbb{R}^{2\times 2}$
(A는 2x2 행렬)

$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}$

$f(A) = A_{11} + A_{12}^2$ $\quad f(\mathbb{R}^{2\times 2}) \rightarrow \mathbb{R}$

$f\begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix} = 5 + 6^2$

함수 $f(A)$를 행렬 A에 대한 미분한 값.

$$\nabla_A f(A) = \begin{bmatrix} \frac{\partial f}{\partial A_{11}} & \frac{\partial f}{\partial A_{12}} \\ \frac{\partial f}{\partial A_{21}} & \frac{\partial f}{\partial A_{22}} \end{bmatrix}$$

A와 동일한 크기

$$= \begin{bmatrix} 1 & 2A_{12} \\ 0 & 0 \end{bmatrix}$$

행렬 특징 복습

if A가 정사각행렬 $(A \in \mathbb{R}^{n \times n})$

trA = 대각합 = 즉 A_{ii}
$(= tr(A))$

- $trA = trA^T$ Transpose

- $f(A) = trA \cdot B$

  $\nabla_A f(A) = B^T$

$$\begin{array}{cc} A & B \\ \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} & \times \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix} \end{array}$$

$$= \begin{bmatrix} a_{11} \cdot b_{11} + a_{12} \cdot b_{21} & a_{11} b_{21} + a_{12} \cdot b_{22} \\ a_{21} \cdot b_{11} + a_{22} \cdot b_{21} & a_{21} \cdot b_{12} + a_{22} \cdot b_{22} \end{bmatrix}$$

미분한 결과로 도출되는 행렬 = $\begin{bmatrix} b_{11} & b_{21} \\ b_{12} & b_{22} \end{bmatrix}$ $\left(B^T = \begin{bmatrix} b_{11} & b_{21} \\ b_{12} & b_{22} \end{bmatrix} \right)$

a_{11}과 a_{21}에 대응 / a_{12}과 a_{22}에 대응

- $trA \cdot B = trB \cdot A$

- $trA \cdot B \cdot C = tr\, C \cdot A \cdot B$

증명!

- $\nabla_A trAA^TC$
  $= CA + C^TA$
  $= A(C + C^T)$

$\frac{d}{da} a^2 c = 2ac$ 와 유사하게 생각하다?

$J(\theta)$

행렬-벡터 표기법으로 표현.?

$$J(\theta)=\frac{1}{2}\sum_{i=1}^{m}\left(h_\theta(x^{(i)})-y^{(i)}\right)^2$$

X

디자인 매트릭스

eu transpose 붙이기!!!

+ 증명 공부.

알고리즘의 모든 예측값을 담은 벡터

$$X\cdot\theta=\begin{bmatrix} __ & (x^{(1)})^T & __ \\ __ & (x^{(2)})^T & __ \\ & \vdots & \\ __ & (x^{(m)})^T & __ \end{bmatrix}\cdot\underbrace{\begin{bmatrix}\theta_0\\ \theta_1\\ \theta_2\end{bmatrix}}_{=\theta}=\begin{bmatrix} x^{(1)T}\cdot\theta \\ x^{(2)T}\cdot\theta \\ \vdots \\ x^{(m)T}\cdot\theta \end{bmatrix}=\begin{bmatrix} h_\theta(x^{(1)}) \\ \vdots \\ h_\theta(x^{(m)})\end{bmatrix}$$

labels

$$y=\begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)}\end{bmatrix}$$

$$\therefore J(\theta)=\frac{1}{2}(X\theta-y)^T\cdot(X\theta-y)$$

$$X\theta-y=\begin{bmatrix} h_\theta(x^{(1)})-y^{(1)} \\ \vdots \\ h_\theta(x^{(m)})-y^{(m)}\end{bmatrix}$$

이것도 벡터임.

학습알고리즘이 m개의 예제에서 저지른 모든 실수를 나타냄.

∴ 각요소 제곱의합으로 나타낼 수 있다.

(모든 그차의 제곱합을 취함으로써 $J(\theta)$가 구해진것임)

(벡터)

$$\cdot\ z^T\cdot z=\sum_i (z_i)^2$$

$$\nabla_\theta J(\theta) = \nabla_\theta \frac{1}{2}(X\cdot\theta - y)^T \cdot (X\cdot\theta - y)$$

$$= \frac{1}{2}\nabla_\theta (\theta^T X^T - y^T)(X\cdot\theta - y)$$

가능의노트 — 행렬미분

$$= \frac{1}{2}\nabla_\theta \left[\theta^T X^T X\theta - \theta^T X^T y - y^T X\theta + y^T y\right]$$

$$= \frac{1}{\cancel{2}}\cdot\cancel{2}(X^T X\theta - X^T y)$$

$$= X^T X\theta - X^T y \overset{set}{=} \vec{0}$$

normal Equation ...

$$X^T X\theta = X^T y$$

$$\theta = (X^T X)^{-1}\cdot X^T y$$

의회적곱시 = 다르다.

만약 X가 역행렬을 갖지않으면?

→ 일반적으로 '중복' 또는 특징들이 있다는 것을 의미. (선형적으로 종속되어있다)

→ 유사 역행렬이란 걸 사용하면 된다.

선생님曰: 보통 어떤 특징이 반복되는지 파악하며 노력할것.